

이미지 유사사례 검색 Threshold 설계 보고서

TUKTAK AI 견적 서비스 - 이미지 임베딩 모델 / 유사도 검색 방식 / 파라미터 설계

1. 목적

사용자가 업로드한 수리 이미지와 기존 수리 사례 이미지 간 유사도를 계산하여, 실제로 유사한 사례만 견적 산정에 활용하기 위한 이미지 유사도 threshold 기준을 설정한다.

잘못된 유사사례가 견적에 사용되면 예상 금액과 수리 시간이 부정확해질 수 있으므로, 오답 사례 유입을 최소화하는 방향으로 설계한다.

2. 이미지 임베딩 모델 후보

모델	선택 이유
CLIP	기존 기준 모델. 이미지-텍스트 의미 매칭에 강하지만 이미지 간 미세 손상 비교에는 한계가 있어 baseline으로 사용한다.
DINOv2	이미지 자체의 형태, 질감, 패턴 등 시각 특징 추출에 강해 이미지-이미지 유사사례 검색에 적합한 대안 모델이다.
ConvNeXt	CNN 기반 모델로 표면 질감, 얼룩, 균열, 파손 같은 집수리 이미지 특징 비교에 적합할 가능성이 있다.

3. 유사도 검색 방식

이미지는 선택한 임베딩 모델을 통해 벡터로 변환한다. 기존 사례 이미지는 미리 임베딩하여 ChromaDB에 저장하고, 사용자가 이미지를 업로드하면 같은 모델로 임베딩한 뒤 ChromaDB에서 유사한 벡터를 검색한다.

유사도 계산 방식은 cosine similarity를 사용한다. 서로 다른 모델에서 생성된 벡터는 같은 공간의 벡터가 아니므로 비교하지 않는다.

4. 주요 파라미터

파라미터	의미
embedding_model	사용할 이미지 임베딩 모델. CLIP, DINOv2, ConvNeXt를 비교한다.
similarity_metric	유사도 계산 방식. cosine similarity를 사용한다.
top_k	검색할 유사 후보 개수. 초기값은 10으로 설정한다.
category_threshold	카테고리별 유사도 통과 기준. 실험으로 결정한다.
min_similar_cases	유사사례 기반 견적에 필요한 최소 사례 수. 초기값은 3으로 설정한다.
fallback_rule	기준 미달 시 LLM/기준표/평균데이터 기반 견적으로 분기한다.

5. Threshold 설계 기준

수리 카테고리마다 이미지 구분 난이도가 다르기 때문에 하나의 공통 threshold를 사용하지 않고, 카테고리별 threshold를 설정한다. 예를 들어 타일 균열/파손은 높은 threshold가 필요하고, 곰팡이/오염은 시각 특징이 뚜렷해 비교적 낮은 threshold가 가능할 수 있다.

선택 우선순위: 1순위 오답 사례 통과 최소화, 2순위 정답 사례 통과 수 확보, 3순위 유사사례 부족 시 LLM/기준표 기반 견적으로 분기