

TUKTAK LLM 성능평가 보고서

집수리 요청 문장을 견적 API에 필요한 구조화 라벨과 예상 금액/시간 필드로 변환하는 LLM 후보 모델 비교 결과입니다.

운영 안정성 후보 Llama 100개 에러 0건	작업 매핑 우세 GPT-OSS 작업 relaxed 0.47	제외 판단 Qwen 100개 에러 78건
--	--	--------------------------------------

핵심 요약

30개 예비 평가에서는 Qwen이 높은 성능을 보였으나, 100개 확장 평가에서는 Qwen의 API/출력 오류가 78건 발생하여 운영 후보에서 제외하는 것이 타당합니다. 정식 서비스 배포 관점에서는 단순 정확도보다 응답 안정성이 중요하므로 Llama를 기본 후보로 두고, GPT-OSS는 예상 작업 매핑 보완 후보로 검토하는 전략이 적절합니다.

STEP 0 평가 설계

구분	내용
평가 목적	사용자 수리 설명을 견적 API에 필요한 구조화 라벨과 금액/시간 필드로 변환하는 성능 확인
비교 모델	Llama, GPT-OSS, Qwen
평가 방식	30개 예비 평가 후 100개 확장 평가로 재검증
채점 기준	strict match와 relaxed match를 함께 사용. 최종 판단은 relaxed와 에러 수 중심
주의 사항	이미지 모델 평가는 별도 담당이며, 본 보고서는 텍스트 LLM 구조화 성능만 다룸

STEP 1 평가 데이터와 출력 필드

출력 필드	평가 의미
main_category	수리 대분류 예측 정확도
object_label	수리 대상 예측 정확도
problem_label	문제 유형 예측 정확도
repair_task	예상 작업 매핑 정확도
missing_info	견적에 부족한 정보 추출
validity_label	정상/애매함/비수리 요청 등 입력 유효성 판단
min/max price, min/max time	금액과 시간 값이 서비스에서 사용할 수 있는 형식인지 확인

STEP 2 30개 예비 평가 결과

30개 평가는 모델 후보를 빠르게 비교하기 위한 예비 검증입니다. 표본 수가 작기 때문에 최종 선정 근거라기보다 방향성 확인에 가깝습니다.

모델	에러	대분류	대상 relaxed	문제 relaxed	작업 relaxed	유효성
Llama	0	0.93	0.87	0.60	0.47	0.73
GPT-OSS	1	0.87	0.97	0.70	0.67	0.77
Qwen	0	0.90	0.97	0.87	0.77	0.90

해석


30개 예비 평가에서는 Qwen이 relaxed 기준에서 가장 좋아 보였습니다. 다만 30개는 표본 수가 작고, API/출력 안정성이 충분히 드러나지 않을 수 있으므로 100개 확장 평가가 필요했습니다.

STEP 3 100개 확장 평가 결과

모델	에러	대분류	대상 relaxed	문제 relaxed	작업 relaxed	유효성
Llama	0	0.64	0.76	0.30	0.29	0.83
GPT-OSS	5	0.62	0.79	0.33	0.47	0.79
Qwen	78	0.15	0.18	0.12	0.13	0.20

색상 기준: Llama=파랑, GPT-OSS=초록, Qwen=주황

100개 확장 평가 핵심 지표




STEP 4 응답 안정성과 평가 변화

운영 서비스에서는 모델이 가끔 더 높은 점수를 내는 것보다, 건적 생성 흐름을 끊지 않고 안정적으로 응답하는지가 중요합니다.

색상 기준: Llama=파랑, GPT-OSS=초록, Qwen=주황

100개 평가 모델별 API/출력 에러 수



모델	대상 변화	문제 변화	작업 변화	유효성 변화
Llama	-0.11	-0.30	-0.18	+0.10
GPT-OSS	-0.18	-0.37	-0.20	+0.02
Qwen	-0.79	-0.75	-0.64	-0.70

Qwen 점수 하락 원인

Qwen은 30개 예비 평가에서는 높은 성능을 보였지만, 100개 확장 평가에서 78건의 API/출력 오류가 발생했습니다. 따라서 점수 하락은 채점 기준이 과도하게 엄격해서가 아니라, 현재 Groq API 환경과 본 프롬프트 조건에서 응답 안정성이 낮게 나타났기 때문입니다.

Strict와 Relaxed 평가 기준

기준	설명	예시
strict	문자열이 거의 정확히 일치해야 정답 처리	정답: 문 / 예측: 방문 -> 오답
relaxed	서비스 기준상 의미가 같은 라벨이면 정답 처리	정답: 문 / 예측: 방문 -> 정답 처리 가능

STEP 5 최종 서비스 후보 판단

모델	최종 판단	근거
Llama	기본 운영 후보	100개 평가 에러 0건. 유효성 판단 0.83, 금액/시간 형식 1.00으로 안정적
GPT-OSS	보조 후보	예상 작업 relaxed 0.47로 가장 높음. 다만 에러 5건 발생
Qwen	제외 후보	100개 평가 에러 78건으로 운영 안정성 부족

최종 결론

정식 서비스 배포 기준으로는 Llama를 기본 모델로 선택하고, GPT-OSS는 예상 작업 매핑 성능 보완용 후보로 유지하는 것이 가장 현실적입니다. TUKTAK 서비스에서는 LLM 결과를 그대로 견적으로 확정하기보다, Llama의 안정적인 구조화 결과를 기준표와 매핑 로직으로 보정하고 사용자가 확인/수정할 수 있게 제공하는 구조가 적합합니다.

운영 적용 제안

단계	내용
1차	Llama로 기본 구조화 결과 생성
2차	repair_task와 가격 기준표를 매핑해 예상 금액/시간 보정
3차	신뢰도 낮음 또는 정보 부족 시 사용자 확인 질문 표시
보완	price_only, unsafe_input, image_required 등은 룰 기반 pre-filter 추가

산출 파일

파일	위치
Streamlit 보고서	/Users/jeonjiwon/Desktop/final project/llm-eval-100/streamlit_report.py
100개 분석 노트북	/Users/jeonjiwon/Desktop/final project/llm-eval-100/notebooks/llm_eval_100_analysis.ipynb
모델 비교 요약 CSV	/Users/jeonjiwon/Desktop/final project/llm-eval-100/results/model_comparison_summary.csv
PDF 보고서	/Users/jeonjiwon/Desktop/final project/llm-eval-100/output/pdf/TUKTAK_LLM_성능평가_보고서_30_100.pdf