

사진 품질 검사 모델 선정 최종 보고서

1. 테스트 요약

사진 품질 검사(초점 불량/저조도/과다노출/저해상도) 4개 모델(OpenCV baseline, BRISQUE, NIMA, 커스텀 CLIP/ResNet18 분류기)을 총 3단계 실험 + 통계적 검정을 거쳐 비교했다. 손상 탐지(구조적 결함) 성격의 데이터 (MVTec)는 과제 범위가 아니므로 최종 검정에서 제외했다.

- 1 차: MIT Indoor Scenes 합성 결함(780 장) — 점 추정치 비교
- 2 차: 실사 블러+저조도, 클래스 불균형(1,650 장) — 점 추정치 비교
- 3 차: 경계선급 결함 + 1:1 균형(490 장) — 부트스트랩 신뢰구간 도입
- 4 차(통계 검정): 페어드 부트스트랩 검정(같은 사진 기준 짝비교) + 다중 시드 재학습으로 결과의 통계적 유의성 확정

용어 정의: 본 보고서에서 v1은 커스텀 분류기를 합성 데이터(1차)만으로 학습한 최초 버전을, v2는 여기에 3차 단계에서 실사 데이터 일부(균형 데이터의 30%)를 섞어 재학습한 버전을 가리킨다. OpenCV·BRISQUE·NIMA는 재학습 대상이 아니므로 버전 구분이 없다(3-1절 참고).

2. 데이터 구성 방법

2-1) 합성 데이터 제작 방법

실 서비스 사진이 아직 없는 초기 단계라, 공개 데이터셋의 정상 사진에 코드로 결함을 합성해 1차 학습·평가 데이터를 만들었다.

- 정상 사진 원본: MIT Indoor Scenes(Kaggle) 중 인테리어 관련 13 개 카테고리(bathroom, bedroom, kitchen, livingroom, closet, corridor, garage, laundromat, dining_room, pantry, nursery, children_room, office) 각 40 장씩 총 520 장
- 합성 결함 생성(augment_defects.py): 정상 사진 1 장마다 아래 4 가지 처리를 적용해 결함 사진 4 장을 자동 생성 → 520 장 × 4 종 = 2,080 장
 - blur(초점 불량): Gaussian Blur 필터 적용(커널 크기 15)
 - low_light(저조도): 전체 픽셀 밝기를 35%로 낮춤
 - overexposed(과다노출): 전체 픽셀 밝기를 1.8 배로 높임
 - low_resolution(저해상도): 15% 크기로 축소 후 원래 크기로 재확대해 디테일 손실 유발
- 정상 520 장 + 결함 2,080 장 = 총 2,600 장을 train 1,820 장 / test 780 장으로 defect_type 비율을 유지하며 분리(stratified split)

3차 실험의 "경계선급 결함"은 같은 방식을 mild/moderate/severe 3단계 강도로 세분화한 버전이다(예: blur 커널 크기 5/11/19, 밝기 배율 0.70/0.50/0.30 등) — 극단적인 결함뿐 아니라 "살짝 흔들린/살짝 어두운" 애매한 사진에서도 모델이 잡아내는지 확인하기 위해 추가했다.

2-2) 실사 데이터 출처

- 실사 블러: kwentar/blur-dataset(Kaggle) — 스마트폰으로 실제 촬영한 sharp/아웃포커스흐림/손떨림흐림 사진
- 실사 저조도: ExDark(Kaggle: washingtongold/exdark-dataset) — 실제 저조도 환경에서 촬영된 사진

두 데이터셋 모두 인테리어 도메인은 아니지만(일반 사물·풍경 사진), "실제 카메라로 촬영하다 생긴 진짜 블러·저조도"라는 점에서 합성 데이터의 한계(균일한 인위적 왜곡)를 보완하는 목적으로 사용했다.

3. 라운드별 성능 요약 (ROC-AUC, 참고용)

모델	1차 합성	2차 실사(불균형)	3차 균형(v1 재평가)	3차 균형(v2 재평가)
OpenCV baseline	0.875	0.790	0.722	0.722
BRISQUE	-	0.681	0.734	0.734
NIMA	-	0.648	0.684	0.684
커스텀 분류기	0.974 (v1)	0.799 (v1)	0.794 (v1)	0.709 (v2, 재학습)

v2(합성+실사 혼합 재학습)는 실사 비율이 낮고 경계선급 합성 결함 위주로 구성되어 v1보다 오히려 성능이 낮아짐. 다중 시드 재학습(5회, seed 1~5)으로 v2의 변동 범위(0.7114~0.7450)를 확인한 결과 v1의 0.7939는 이 범위를 벗어나 — v1의 우위가 학습 노이즈가 아닌 실질적 차이임을 확인.

표 요약

각 행(모델)을 왼쪽에서 오른쪽으로 보면 테스트 조건이 까다로워질수록(1차 합성 → 2차 실사 → 3차 균형) 점수가 어떻게 변하는지 보인다. OpenCV/BRISQUE/NIMA는 재학습 대상이 아니므로 마지막 두 열(v1 재평가/v2 재평가)의 값이 서로 같다 — 오직 커스텀 분류기만 재학습 전(v1)/후(v2)로 값이 달라진다. BRISQUE는 1차에 값이 없는데(-), 1차 실험 시점에는 아직 도입 전이었기 때문이다. 이 표만으로는 "커스텀 분류기가 대체로 가장 높다"는 인상을 주지만, 그 차이가 통계적으로 유의미한지는 4장에서 별도로 검정한다.

3-1) 참고 - 모델별 추론 속도 · 크기 비교

OpenCV/BRISQUE/NIMA 3개는 우리가 직접 학습시키는 모델이 아니다 — OpenCV는 고정된 수학 공식(학습 파라미터 자체가 없음)이고, BRISQUE·NIMA는 pyiqa 라이브러리가 이미 다른 데이터로 학습해둔 가중치를 다운로드해 그대로 추론에만 쓴다. 반면 커스텀 분류기는 이번 프로젝트에서 유일하게 우리 데이터로 직접 학습(train_custom_classifier.py)시키는 모델이다. "직접 학습시키는 모델이니 더 무겁고 느릴 것"이라는 예상과 달리, 실측 결과는 정반대였다.

모델	추론 속도	모델 크기	비고
OpenCV baseline	15.1 ms/장	-	학습/가중치 파일 없음
BRISQUE	41.3 ms/장	0.0MB	사전학습 가중치 (직접 학습 안 함)
NIMA	49.3 ms/장 (최저)	207.5MB (최대)	사전학습 가중치 (직접 학습 안 함)
커스텀 분류기	14.8 ms/장 (최고)	42.7MB	직접 학습 (ResNet18 전이학습, 11,177,538 파라미터, 학습 271초 /10epoch)

커스텀 분류기가 4개 중 추론 속도가 가장 빠르고(GPU에서 ResNet18이 NIMA의 Inception 계열보다 경량), 모델 크기도 BRISQUE(사실상 0MB의 SVM) 다음으로 작다. 반대로 NIMA는 "우리가 학습시키지 않은 기성 모델"임에도 속도·크기 모두 4개 중 가장 열세다 — "직접 학습(커스텀 모델) = 무겁고 느림, 기성 모델 = 가볍고 빠름"이라는 일반적 통념이 이번 비교에서는 성립하지 않았다.

4. 통계적 검정 결과 (핵심)

4-1) 균형 테스트셋(v3, 490장, 실사+경계선급 혼합) 기준 - 페어드 부트스트랩

비교	AUC 차이	p-value	판정
커스텀분류기(v1) vs BRISQUE	+0.060	0.047	유의미함 (커스텀 우위)
커스텀분류기(v1) vs NIMA	+0.112	<0.001	유의미함 (커스텀 우위)
커스텀분류기(v1) vs OpenCV	+0.072	0.016	유의미함 (커스텀 우위)
BRISQUE vs NIMA / OpenCV	-	0.08~0.66	유의미하지 않음

v1 기준으로는 커스텀 분류기가 3개 모델 모두를 통계적으로 유의미하게 앞선다. 다만 이 테스트셋은 불량 사진의 74%가 "실사 정상 사진에 합성 결함을 입힌 것"이라 완전한 순수 실사로 보기는 어렵다.

표 요약

"AUC 차이"는 왼쪽 모델 점수에서 오른쪽 모델 점수를 뺀 값으로, 양수면 왼쪽 모델이 더 우수하다는 뜻이다. "p-value"는 "두 모델의 실력이 사실은 같은데 우연히 이만큼 차이가 났을 확률"이며, 0.05보다 작으면 우연이라 보기 어려워 "진짜 차이가 있다"고 판단한다.

4-2) 순수 실사 테스트셋(2차, 1,650장, 합성 결함 0%) 기준 — 페어드 부트스트랩

비교	AUC 차이	p-value	판정
커스텀분류기(v1) vs NIMA	+0.152	<0.001	유의미함 (커스텀 우위)
커스텀분류기(v1) vs BRISQUE	+0.118	<0.001	유의미함 (커스텀 우위)
커스텀분류기(v1) vs OpenCV	+0.009	0.616	유의미하지 않음 (동률)
OpenCV vs BRISQUE	+0.109	<0.001	유의미함 (OpenCV 우위)
OpenCV vs NIMA	+0.142	<0.001	유의미함 (OpenCV 우위)
BRISQUE vs NIMA	-	0.107	유의미하지 않음

100% 순수 실사 데이터라는 가장 엄격한 기준에서는, "커스텀 분류기 $\approx$ OpenCV baseline > BRISQUE $\approx$ NIMA" 구도가 확정된다. 커스텀 분류기의 BRISQUE·NIMA 대비 우위는 두 테스트셋에서 모두 재현되어 신뢰도가 높다. 반면 커스텀 분류기의 OpenCV 대비 우위는 순수 실사에서는 재현되지 않았다 — 4-1의 결과는 합성 결함이 섞인 데이터 특성에 기인한 것으로 해석된다.

표 요약

표 구성은 4-1과 동일하되, 이번엔 합성 결함이 전혀 섞이지 않은 순수 실사 사진 1,650장으로 검정했다는 점이 다르다. 가장 주목할 부분은 셋째 줄 "커스텀분류기(v1) vs OpenCV: p=0.616"이다. 4-1에서는 커스텀 분류기가 OpenCV를 유의미하게 이겼지만(p=0.016), 순수 실사에서는 그 차이가 사라졌다(p=0.616은 0.05보다 훨씬 크다) — 즉 "커스텀이 OpenCV를 이긴다"는 결과는 순수 실사에서는 재현되지 않는다. 반면 커스텀·OpenCV가 각각 BRISQUE·NIMA를 이기는 결과는 두 표 모두에서 p<0.001로 일관되게 나타나, 이 부분은 신뢰도가 높다.

5. 최종 결론

모델	채택 여부	근거
BRISQUE	제외	모든 테스트셋에서 OpenCV-커스텀분류기 대비 유의미하게 낮음
NIMA	제외	모든 테스트셋에서 OpenCV-커스텀분류기 대비 유의미하게 낮음, 속도·크기도 최하
OpenCV baseline	1순위 후보	순수 실사 기준 커스텀분류기와 통계적 동률, 무료·고속·설명 가능
커스텀 분류기 (v1)	1순위 후보	순수 실사 기준 OpenCV와 통계적 동률, 향후 실사 데이터로 성능 개선 여지 있음

표 요약

4장의 통계 검정 결과를 "채택 여부"라는 의사결정으로 번역한 표다. BRISQUE·NIMA는 "제외"로 명확히 정리되지만, OpenCV와 커스텀 분류기는 둘 다 "1순위 후보"로 동점 처리되어 있다 — 성능만으로는 승부가 나지 않았기 때문이다. 이 동점을 어떻게 풀지가 바로 다음 표(5-1)의 역할이다.

5-1) OpenCV baseline vs 커스텀 분류기 — 운영 기준 비교

기준	OpenCV baseline	커스텀 분류기 (v1)
순수 실사 성능(ROC-AUC)	0.790	0.799 (통계적 동률)
추론 속도	15~45ms/장 (가장 빠름)	15~40ms/장
인프라 비용	없음 (클라우드 베이스)	GPU 권장, 모델 파일 42.7MB
판정 근거 설명력	높음 (초점/노출 등 사유 제시 가능)	낮음 (블랙박스)
향후 개선 여지	제한적 (임계값 튜닝 수준)	높음 (실사 데이터 축적 시 성능 향상 기대)
유지보수 부담	낮음	재학습 파이프라인 관리 필요

표 요약

성능(첫 행)이 통계적으로 동률이라고 나온 두 모델을, 성능이 아닌 5가지 실무 기준으로 나란히 비교했다. 대부분의 기준에서 OpenCV는 "당장 쓰기 편함" 쪽이고, 커스텀 분류기는 "지금엔 비슷하지만 나중에 더 좋아질 잠재력"을 가진 쪽이다.

6. 최종 권고안

- 성능만으로는 OpenCV baseline 과 커스텀 분류기(v1) 중 어느 쪽도 통계적으로 우월하지 않으므로, 운영 비용·설명가능성 관점에서 결정하는 것을 권장한다
- 단기(즉시 배포): OpenCV baseline — 인프라 비용이 없고 판정 사유를 사용자에게 안내하기 쉬움
- 중장기: 커스텀 분류기에 실사 데이터를 지속 축적해 재학습 — 이번 v2 시도는 실사 비율 부족의 문제가 있었으나, 방향 자체는 유효하며 데이터가 쌓이면 OpenCV 를 능가할 잠재력이 있음(1 차 합성 데이터에서는 이미 압도적 우위 확인됨)
- BRISQUE/NIMA 는 이번 프로젝트에서 완전히 제외 권장 — 모든 테스트에서 유의미하게 열세이며 속도·크기도 불리함

6-1) 참고 — 이전 앙상블 실험 결과 (3차, 균형 490장, 커스텀분류기 v2 기준)

최종 채택 검토 전, 3차 실험에서 OpenCV baseline과 커스텀 분류기(v2)를 Youden 임계값 기준으로 OR/AND 결합해 본 결과는 아래와 같다. 이때는 v2(재학습에 실패해 v1보다 약한 버전)를 사용했음에도 OR 결합에서 Recall이 크게 상승했다.

결합 방식	Recall	Precision	FPR
OpenCV baseline 단독	57.6%	74.2%	20.0%
커스텀분류기(v2) 단독	64.9%	69.1%	29.0%
OR 결합 (둘 중 하나라도 불량)	86.5%	68.4%	40.0%
AND 결합 (둘 다 불량)	35.9%	80.0%	9.0%

OR 결합으로 Recall이 개별 모델 대비 20%p 이상 상승했다(64.9% → 86.5%). 두 모델이 서로 다른 이유로 틀리기 때문에 나타난 시너지로 해석되며, 이 프로젝트가 최우선으로 삼는 Recall 극대화 목표에 부합하는 결과다. 다만 이때 쓰인 커스텀 분류기는 성능이 낮은 v2였다는 한계가 있다.

표 요약

"OR 결합"은 두 모델 중 하나라도 "불량"이라고 판정하면 최종적으로 불량 처리하는 방식이고, "AND 결합"은 둘 다 "불량"이라고 해야 최종 불량 처리하는 방식이다. OR은 Recall(실제 불량 중 잡아낸 비율)을 높이는 대신 Precision-FPR이 나빠지고(정상 사진을 더 자주 오탐), AND는 반대로 Recall이 떨어지는 대신 Precision이 좋아진다. Recall을 최우선으로 하는 이 프로젝트에는 OR 결합이 방향상 더 잘 맞는다.

6-2) 추가 검토 제안

- OpenCV 와 커스텀분류기(v1, 재학습 실패 이전의 원래 성능 좋은 버전)의 앙상블(OR 결합)을 재검증 — v2 보다 더 강한 v1 으로 결합하면 Recall 상승폭이 더 커지거나, 반대로 두 모델의 예측이 더 비슷해져 시너지가 줄어들 수도 있어 직접 확인이 필요함
- OR 결합의 Precision/FPR 하락(69%→68%, 29%→40%) 정도가 실서비스에서 감내 가능한 수준인지 비즈니스 판단 필요

7. 참고 자료

[IQA-PyTorch\(pyiq\) — GitHub](#)

[MIT Indoor Scenes \(Kaggle\)](#)

[실사 블러 데이터셋 \(Kaggle\)](#)

[ExDark 데이터셋 \(Kaggle\)](#)